

基于 BiLSTM-CRF 的中文命名实体识别

GitHub 项目地址

本项目的完整代码与实验报告已同步开源至 GitHub：[SequenceAnnotation](#)

训练好的模型（利用4090训练了20轮，共40mins）位置：[best.pt](#)

一、实验目的与任务要求

本实验的目标是利用深度学习模型完成 **序列标注任务**，要求识别出文本中的 **人名**、**地名** 和 **组织机构名**。

实验使用 1998 年《人民日报》语料中的中文数据集，格式如下：

- `train_corpus.txt`: 训练文本
- `train_label.txt`: 对应的标签
- `test_corpus.txt`: 测试文本
- `test_label.txt`: 对应的标签

评价指标要求：

使用 **准确率 (Accuracy)**、**召回率 (Recall)**、**F1 值 (F1-Score)** 进行模型评估，并分别计算：**1** 包含“O”标签的整体指标 **2** 去除“O”标签后的实体识别指标。

二、模型结构与方法说明

1 模型选择

本实验选用 **BiLSTM + CRF**（双向长短时记忆网络 + 条件随机场）模型。

原因如下：BiLSTM 能捕捉上下文双向依赖信息，对序列任务效果显著；并且相比传统 LSTM 方法，BiLSTM-CRF 更适合中文 NER 任务。

2 模型结构

```
输入序列（字符级别）
↓
Embedding 层（向量化）
↓
双向 LSTM 层（上下文特征抽取）
↓
线性层（映射至标签空间）
↓
CRF 层（序列条件解码）
↓
输出预测标签序列
```

损失函数为 CRF 的负对数似然（NLL），优化器采用 Adam。

3 模型具体参数

模块	实现方式
嵌入层（Embedding）	随机初始化，可学习
BiLSTM 隐层维度	256
CRF 解码	采用维特比算法求最优路径
Dropout	0.3
优化器	Adam
学习率	1e-3
最大轮数	20 轮
Batch Size	32

三、实验环境

环境项	配置
操作系统	Ubuntu 18.04
Python 版本	3.8
深度学习框架	PyTorch 2.4.1
CUDA 版本	11.3
GPU	NVIDIA RTX 4090（24GB）
依赖安装	<code>pip install -r requirements.txt</code>

四、实验结果

✓ 含“O”类别（整体性能）

指标	值
Accuracy	0.9805
Recall	0.9805
F1	0.9805

✓ 去“O”类别（实体识别性能）

指标	值
Accuracy	0.9805
Recall	0.8663
F1	0.8883

所有评测结果自动保存至：

```
outputs/eval_results.txt
```

五、结果分析与思考

整体来看，**整体准确率较高（97%）**，说明模型对非实体字符预测稳定；并且**实体识别 F1 $\approx$ 0.88**反映了BiLSTM能较好捕捉上下文特征。

六、运行说明

```
# 训练模型
python train.py

# 评估最优模型
python evaluate.py

# 预测并保存实体
python predict.py
```

预测结果保存在：

```
outputs/test_entities.tsv
```